DOKUMENTASI SISTEM

Question Answering Publikasi Statistik BPS

Sistem Retrieval-Augmented Generation berbasis Small Language Model

Panduan penggunaan, arsitektur, instalasi, API, dan pengoperasian

Versi	1.0
Tanggal	16 Oktober 2026
Demo web	https://qapublikasi.skripsi.uk
Repository	https://github.com/Makaareeem/archive-skripsi-nabil/Artefact

Daftar Isi

1. Pendahuluan 3
1.1 Tujuan dokumen 3
1.2 Sasaran pembaca 3
1.3 Akses sistem 3

2. Panduan Penggunaan Web 3
2.1 Gambaran aplikasi 3
2.2 Langkah penggunaan 4
2.3 Contoh pertanyaan 4
2.4 Membaca hasil 5

3. Alur Retrieval-Augmented Generation 5
3.1 Tahapan pemrosesan 5
3.2 Model dan basis pengetahuan 6
3.3 Pemeriksaan jawaban 6

4. Komponen Perangkat Lunak 6
4.1 Struktur repository 6
4.2 Batas proses dan antrean 7

5. Menjalankan Sistem secara Lokal 7
5.1 Prasyarat 7
5.2 Instalasi 7
5.3 Konfigurasi utama 8

6. API dan Format Hasil 8
6.1 Daftar endpoint 8
6.2 Format permintaan 9
6.3 Format respons 9
6.4 Streaming 9
6.5 Kode kesalahan 9

7. Deployment dan Pengoperasian 10
7.1 Arsitektur deployment 10
7.2 Runpod 10
7.3 Cloudflare 10
7.4 Operasi harian 11

8. Pengujian dan Batasan 11
8.1 Pengujian yang tersedia 11
8.2 Batasan sistem 12
8.3 Pengembangan lanjutan 12

1. Pendahuluan

1.1 Tujuan dokumen

Sistem Question Answering (QA) Publikasi Statistik BPS menjawab pertanyaan tentang publikasi statistik Badan Pusat Statistik dengan mencari potongan dokumen yang relevan, menyusun jawaban menggunakan model bahasa, lalu menampilkan sumber yang dipakai. Dokumen ini menjelaskan cara menggunakan aplikasi, cara kerja sistem, instalasi, API, serta pengoperasian layanan.

1.2 Sasaran pembaca

Tabel 1. Sasaran pembaca dan bagian yang relevan

Pembaca	Kebutuhan	Bagian
Pengguna aplikasi	Mengajukan pertanyaan dan membaca hasil beserta sumbernya	Bab 2
Pengembang	Memahami alur RAG, komponen, instalasi lokal, dan API	Bab 3 – 6
Pengelola layanan	Menjalankan deployment, memantau operasi, dan memahami batasan	Bab 7 – 8

1.3 Akses sistem

Aplikasi dapat dijalankan secara lokal atau melalui deployment Cloudflare dan Runpod.

Tabel 2. Tautan sistem

Sumber	Alamat
Demo web	https://qapublikasi.skripsi.uk
Repository	https://github.com/Makaareeem/SistemQAPublikasi

2. Panduan Penggunaan Web

2.1 Gambaran aplikasi

Question Answering Publikasi Statistik BPS adalah aplikasi web yang menjawab pertanyaan berdasarkan teks publikasi statistik. Antarmuka menampilkan jawaban umum, nomor sitasi, cuplikan asli, judul publikasi, halaman, tautan sumber, dan skor relevansi. Jawaban dihasilkan dari dokumen yang berhasil ditemukan; sumber yang tidak lolos pemilihan tidak dijadikan dasar jawaban.

API untuk pengguna selalu memakai RAG. Jalur evaluasi terpisah tersedia bagi penelitian dan nonaktif secara default.

> **Penting.** Sistem tidak dimaksudkan sebagai pengganti pemeriksaan langsung pada publikasi ketika angka atau definisi akan digunakan sebagai rujukan resmi.

2.2 Langkah penggunaan

Buka https://qapublikasi.skripsi.uk melalui browser. Aplikasi dapat digunakan langsung tanpa username, password, atau pendaftaran. Halaman awal tidak menyalakan model secara otomatis; server disiapkan ketika pertanyaan pertama dikirim.

1. **Pilih pengaturan.** Pada halaman awal, pilih model dan panjang jawaban **Ringkas** atau **Detail** di bawah kotak pertanyaan.
2. **Tulis pertanyaan.** Gunakan pertanyaan statistik yang spesifik; sebutkan indikator, wilayah, periode data, dan kelompok penduduk bila diperlukan. Tekan Enter atau pilih **Tanyakan** untuk mengirim; Shift+Enter membuat baris baru.
3. **Tunggu penelusuran.** Pada layanan yang sedang tidak aktif, server dan model disiapkan lebih dahulu sehingga permintaan pertama dapat lebih lama. Hindari mengirim pertanyaan yang sama berulang kali saat menunggu.
4. **Pantau proses.** Buka panel proses untuk melihat perluasan pertanyaan, pencarian, sumber terpilih, dan penyusunan jawaban. Panel dapat disembunyikan dan dibuka lagi setelah jawaban selesai.
5. **Periksa jawaban dan sitasi.** Nomor [1], [2], dan seterusnya mengarah ke kartu sumber berisi judul publikasi, halaman, skor relevansi, dan cuplikan asli. Buka tautan publikasi untuk memeriksa konteks data.
6. **Ajukan pertanyaan berikutnya.** Pilih **Ubah** pada ringkasan pertanyaan untuk membuka kotak masukan. Pilih **Kembali ke hasil** jika ingin menutupnya tanpa mengirim pertanyaan baru.
7. **Batalkan bila perlu.** Pilih **Batalkan** untuk menghentikan permintaan yang masih berjalan. Jika layanan sibuk atau muncul pemberitahuan kesalahan, tunggu sebentar lalu coba lagi. Jangan gunakan jawaban sementara yang belum selesai sebagai hasil akhir.

Menu **Cara pakai** dan **Cara kerja** di bagian atas halaman menyediakan panduan singkat. Jika muncul pemberitahuan terlalu banyak permintaan dari jaringan yang sama, tunggu sekitar satu menit sebelum mencoba lagi.

2.3 Contoh pertanyaan

Tabel 3. Contoh pertanyaan yang diterima dan ditolak

Pertanyaan	Keterangan
"Apa yang dimaksud dengan Tingkat Pengangguran Terbuka?"	Diterima: menanyakan definisi indikator.
"Bagaimana tingkat kemiskinan Jawa Tengah pada tahun 2024?"	Diterima: menyebut indikator, wilayah, dan periode.
"cek"	Ditolak sebelum pencarian karena tidak memuat topik yang cukup.

2.4 Membaca hasil

Tabel 4. Elemen pada halaman hasil

Elemen	Makna
Jawaban	Ringkasan yang dihasilkan model dari sumber terpilih; dapat diperbarui hingga pemrosesan selesai.
Sitasi [n]	Penghubung dari klaim jawaban ke kartu sumber bernomor n.
Cuplikan asli	Bagian teks publikasi yang diambil dari chunk sumber, tanpa ringkasan generatif per sumber.
Skor relevansi	Nilai reranker untuk kecocokan pencarian; bukan persentase keyakinan atau jaminan kebenaran.
Catatan jawaban	Tanda bahwa pemeriksaan dasar menemukan hal yang perlu dibaca ulang pada sumber.

> **Catatan.** Tahun terbit publikasi dapat berbeda dari tahun data yang dibahas. Perhatikan juga apakah suatu angka adalah realisasi, target, rencana, atau proyeksi.

3. Alur Retrieval-Augmented Generation

3.1 Tahapan pemrosesan

Satu permintaan melewati beberapa tahap pada Tabel 5. Pertanyaan asli selalu dipertahankan, sehingga hasil pencarian tidak sepenuhnya bergantung pada kualitas perluasan yang dibuat model.

Tabel 5. Tahapan alur RAG

No	Tahap	Proses
1	Validasi	Memeriksa struktur dan isi pertanyaan sebelum memasukkannya ke antrean.
2	Perluasan	Model membuat paling banyak satu perluasan. Perluasan yang mengubah maksud, angka, atau periode dapat dilewati; cadangan istilah statistik dipakai pada kondisi tertentu.
3	Pencarian	Pertanyaan asli dan perluasan yang valid dicari melalui embedding dan FAISS (dense) serta kecocokan kata BM25 (sparse).
4	Penggabungan	Hasil dense dan sparse digabung menggunakan Reciprocal Rank Fusion (RRF), lalu kandidat dipilih untuk reranking.
5	Reranking	Cross-encoder menilai ulang hingga 20 kandidat berdasarkan pertanyaan asli. Ambang skor dan kapasitas konteks menentukan sumber yang dipakai.
6	Jawaban	Model menyusun jawaban dari maksimal lima chunk utuh, lalu sistem memeriksa sitasi dan beberapa pola angka.

3.2 Model dan basis pengetahuan

Tabel 6. Komponen model

Komponen	Model / teknologi
Model jawaban	Llama 3.2 3B dan Gemma 2 2B, masing-masing versi dasar dan fine-tuned (format GGUF, dijalankan Ollama)
Embedding	Nomic Embed Text v1.5
Reranker	rerank-indonesia (cross-encoder)
Basis pengetahuan	Indeks FAISS dan metadata chunk yang dipakai kembali oleh BM25

Model, indeks, dan metadata tidak disimpan di repository karena ukurannya besar. Pada lokal, aset diperoleh dari Hugging Face saat persiapan pertama. Pada Runpod, versi dan checksum aset dikunci dalam `assets.json` serta disimpan di volume persisten.

3.3 Pemeriksaan jawaban

Sistem memeriksa keberadaan sitasi, nomor sumber, dan beberapa kecocokan angka dengan sumber. Hasil pemeriksaan dasar tidak membuktikan seluruh makna jawaban benar. Kesesuaian indikator, wilayah, populasi, periode data, dan satuan tetap perlu ditinjau ketika jawaban digunakan untuk keputusan penting.

Jika tidak ada sumber yang lolos, sistem memberikan respons bahwa informasi belum ditemukan dalam sumber yang terambil tanpa memanggil model untuk mengarang jawaban. Jika generasi belum menghasilkan ringkasan lengkap, cuplikan sumber dapat ditampilkan sebagai keluaran pengganti yang diberi catatan.

4. Komponen Perangkat Lunak

4.1 Struktur repository

Tabel 7. Struktur direktori repository

Lokasi	Tanggung jawab
`app/`	FastAPI, validasi, antrean, pipeline, retrieval, reranking, generasi, pemeriksaan sumber, dan konfigurasi.
`web/`	Halaman, gaya visual, validasi awal, pembaca SSE, panel proses, dan kartu sumber.
`deploy/`	Registrasi Ollama, Docker image, runtime Runpod, dan gateway Cloudflare.
`tests/`	Tes kontrak API, antrean, pipeline, frontend, dan regresi.
`tools/`	Utilitas benchmark API.

FastAPI menyediakan antarmuka HTTP dan mengelola antrean. Pipeline menggunakan modul retrieval, reranker, prompt, generasi, dan pemeriksaan bukti yang sama untuk endpoint JSON maupun streaming. Frontend menerima pembaruan status dan token melalui Server-Sent Events (SSE).

4.2 Batas proses dan antrean

Satu proses backend memakai dua batas: jumlah pipeline aktif dan jumlah pekerjaan menunggu.

Tabel 8. Profil batas antrean

Profil	Pipeline aktif	Pekerjaan menunggu	Inferensi Ollama paralel
Lokal (contoh)	1	4	–
Runpod	3	4	1

Ketika seluruh slot terisi, API mengembalikan HTTP 429. Antrean berada di memori proses sehingga tidak dipertahankan setelah worker berhenti.

5. Menjalankan Sistem secara Lokal

5.1 Prasyarat

- Python 3.11 dalam environment terpisah.
- Ollama terpasang dan dapat dijalankan.
- Koneksi internet untuk unduhan aset pertama.
- Ruang penyimpanan untuk model dan indeks.
- GPU (opsional) untuk mempercepat inferensi.

5.2 Instalasi

1. Clone repository dari https://github.com/Makaareeem/SistemQAPublikasi.git dan masuk ke direktori proyek.
2. Buat environment Python, aktifkan, lalu instal `requirements.txt`. Pilih build PyTorch yang sesuai dengan perangkat bila instalasi otomatis tidak cocok.
3. Salin `.env.example` menjadi `.env` dan sesuaikan pengaturan yang diperlukan. Jangan masukkan token atau password ke repository.
4. Jalankan Ollama pada terminal terpisah, kemudian daftarkan model GGUF dengan modul `deploy.setup_ollama`.
5. Jalankan FastAPI dengan satu worker dan buka aplikasi pada http://127.0.0.1:8000.

```
python -m pip install -r requirements.txt
python -m deploy.setup_ollama
python -m uvicorn app.main:app --host 127.0.0.1 --port 8000 --workers 1
```

> **Catatan.** Perintah pendaftaran model dijalankan setelah Ollama aktif. Startup pertama backend menyiapkan indeks, embedding, dan reranker sehingga waktu awal lebih lama. Endpoint `/api/ready` menunjukkan kesiapan backend dan model default.

5.3 Konfigurasi utama

Tabel 9. Variabel lingkungan utama

Variabel	Fungsi	Default lokal
`INFERENCE_URL`	Alamat Ollama	127.0.0.1:11434
`DEFAULT_MODEL_KEY`	Model default	llama3.2-finetuned
`QUEUE_CONCURRENCY`	Pipeline aktif	1
`MAX_QUEUE`	Pekerjaan menunggu	4
`QUEUE_WAIT_TIMEOUT`	Batas waktu antrean	180 detik
`OLLAMA_TIMEOUT`	Batas waktu model	120 detik
`RERANK_SCORE_THRESHOLD`	Ambang skor mentah reranker	-1,0

Nilai deployment Runpod berbeda dari default lokal. Daftar lengkap variabel tersedia dalam `.env.example` dan `deploy/runpod-demo/runpod.env.example`. Ambang reranker menggunakan skor logit mentah, bukan probabilitas.

6. API dan Format Hasil

6.1 Daftar endpoint

Backend menyediakan dokumentasi interaktif pada `/docs` ketika berjalan secara lokal. Gateway publik hanya meneruskan rute yang diperlukan aplikasi web; endpoint penelitian tidak tersedia melalui gateway.

Tabel 10. Endpoint API

Endpoint	Kegunaan
`GET /ping`	Pemeriksaan kesiapan untuk hosting.
`GET /api/health`	Status indeks, Ollama, dan model yang tersedia.
`GET /api/ready`	HTTP 200 ketika backend dan model default siap; HTTP 503 ketika belum siap.
`POST /api/ask`	Jawaban akhir RAG dalam format JSON.
`POST /api/ask/stream`	Tahapan dan jawaban melalui Server-Sent Events.
`POST /api/eval/ask`	Jalur penelitian privat; hanya aktif dengan konfigurasi dan kunci evaluasi.

6.2 Format permintaan

Contoh badan permintaan untuk `POST /api/ask`:

```
{
  "question": "Apa yang dimaksud dengan Tingkat Pengangguran Terbuka?",
  "model_key": "llama3.2-finetuned",
  "use_rag": true,
  "response_style": "ringkas"
}
```

Tabel 11. Parameter permintaan

Parameter	Wajib	Ketentuan
`question`	Ya	Maksimal 1.500 karakter.
`model_key`	Ya	Harus termasuk model yang terdaftar.
`use_rag`	Ya	Wajib bernilai true pada API publik.
`response_style`	Ya	ringkas atau detail.
`top_k`	Tidak	Default 5, rentang 1 sampai 5.

6.3 Format respons

Respons akhir memuat `answer`, `answer_status`, `sources`, `other_sources`, `warnings`, `latency`, `process`, `cache`, `generation_metrics`, `config`, dan `request_id`. Field `sources` berisi metadata

publikasi, nomor sitasi, cuplikan, dan teks chunk, sedangkan `other_sources` memuat publikasi terkait yang tidak digunakan dalam konteks jawaban.

6.4 Streaming

Endpoint streaming mengirim tahapan antrean, ekspansi, pencarian, sumber, generasi, token, jawaban akhir, dan selesai. Token yang tampil saat generasi masih bersifat sementara.

> **Penting.** Klien harus memakai event `answer` atau `done` sebagai hasil akhir karena bagian kalimat yang belum selesai dapat dipotong pada batas keluaran.

6.5 Kode kesalahan

Tabel 12. Kode status kesalahan

Kode	Kondisi
HTTP 422	Kesalahan validasi permintaan.
HTTP 429	Antrean penuh atau batas permintaan terlampaui.
HTTP 503	Backend atau model default belum siap.
Kode aman + request_id	Kegagalan pemrosesan; dapat ditelusuri melalui log tanpa mengungkap rincian internal kepada pengguna.

7. Deployment dan Pengoperasian

7.1 Arsitektur deployment

Deployment memisahkan halaman dan gateway dari komputasi model. Cloudflare Worker menyajikan frontend, membatasi frekuensi permintaan, dan meneruskan rute yang diizinkan ke Runpod. Runpod menjalankan FastAPI, pencarian, Ollama, serta proses model pada satu worker GPU.

```
Browser → Cloudflare Worker (frontend + gateway + rate limit) → Runpod (FastAPI + FAISS/BM25 + Ollama, GPU)
```

7.2 Runpod

Tabel 13. Konfigurasi endpoint Runpod

Pengaturan	Nilai
Dockerfile	deploy/runpod-demo/Dockerfile (dibangun dari root repository)
Tipe endpoint	Load Balancer
Port aplikasi / health	8000 / 8081
Path health	/ping
Volume persisten	/runpod-volume
Worker	Active worker 0, maksimum 1 worker, 1 GPU per worker

Saat active worker 0 dan tidak ada permintaan, komputasi dapat berhenti; permintaan setelah jeda mengalami cold start. Penyimpanan volume tetap berbiaya sesuai pengaturan penyedia walaupun worker tidak aktif. Ketersediaan, harga, serta lama idle merupakan pengaturan layanan dan perlu diperiksa pada konsol Runpod.

7.3 Cloudflare

Cloudflare membangun gateway dari folder `deploy/runpod-demo/gateway` dengan perintah berikut. Build ini membentuk frontend dari folder `web/`. Domain kustom mengarah ke Worker; browser tidak terhubung langsung ke Runpod.

```
cd deploy/runpod-demo/gateway
npm run build
npx wrangler deploy
```

Tabel 14. Binding Cloudflare Worker

Binding	Jenis	Peran
`RUNPOD_ORIGIN`	Variable	Alamat HTTPS endpoint Runpod.
`RUNPOD_API_KEY`	Secret	Autentikasi gateway ke Runpod.
`ASK_RATE_LIMIT`	Rate limit	Lima permintaan jawaban per menit per IP dan lokasi Cloudflare.
`WAKE_RATE_LIMIT`	Rate limit	30 pemeriksaan kesiapan per menit per IP dan lokasi Cloudflare.

> **Keamanan.** Kunci API Runpod hanya disimpan sebagai secret pada Cloudflare Worker dan tidak dikirim ke browser. Gateway membatasi permintaan jawaban dan pemeriksaan kesiapan sebelum menghubungi Runpod. Kunjungan halaman awal tidak membangunkan GPU; tombol Tanyakan memicu pemeriksaan kesiapan server.

7.4 Operasi harian

- Periksa status build Cloudflare, health Runpod, dan kesiapan model setiap kali deployment berubah.
- Pantau waktu antrean, pencarian, generasi, dan respons keseluruhan, beserta penggunaan memori serta biaya GPU dan volume.
- Gunakan `request_id` untuk menelusuri kegagalan pada log backend. Jangan menyalin API key atau data rahasia ke tiket maupun log publik.
- Jika basis pengetahuan atau model diperbarui, ubah manifest aset, verifikasi checksum, lalu uji startup dan kualitas jawaban sebelum merilis.
- Uji kembali kapasitas apabila model, jumlah worker, GPU, atau batas paralel diubah.

8. Pengujian dan Batasan

8.1 Pengujian yang tersedia

Tabel 15. Perintah pengujian

Kelompok	Perintah
Backend	`python -B -m unittest discover -s tests -p "test_*.py" -v`
Frontend	`node --test tests/frontend.test.cjs tests/frontend-audit.test.cjs tests/frontend-ui.test.cjs`
Runpod	`python -B -m unittest discover -s deploy/runpod-demo -p "test_*.py" -v`
Gateway	`cd deploy/runpod-demo/gateway; npm install; npm test`

Tes otomatis memeriksa kontrak dan regresi dengan dependensi simulasi. Pemeriksaan visual browser memerlukan Playwright. Uji inferensi nyata memerlukan Ollama, model, dan basis pengetahuan yang siap. Benchmark API dapat dijalankan melalui `tools/benchmark_api.py` setelah backend aktif.

8.2 Batasan sistem

- **Cakupan data.** Basis pengetahuan saat ini berupa teks chunk publikasi; tabel dan struktur visual PDF belum selalu terwakili dengan baik.
- **Verifikasi.** Skor reranker adalah kecocokan pencarian; pemeriksaan sitasi dan angka belum memverifikasi seluruh hubungan semantik.
- **Ketepatan jawaban.** Model dapat menghasilkan jawaban yang tidak tepat meskipun sumber relevan. Baca publikasi asal sebelum memakai angka sebagai rujukan resmi.
- **Waktu respons.** Waktu respons berubah mengikuti model, pertanyaan, kondisi cache, antrean, dan cold start Runpod.

- **Akses dan biaya.** Layanan web dapat diakses tanpa login. Rate limit Cloudflare membatasi permintaan per alamat IP dan lokasi, tetapi bukan batas biaya global; pemakaian GPU dan biaya tetap perlu dipantau pengelola.

8.3 Pengembangan lanjutan

Pengembangan lebih lanjut dapat diarahkan pada:

- pengolahan tabel pada publikasi PDF;
- evaluasi kualitas jawaban per skenario pertanyaan;
- kalibrasi threshold reranker;
- pengukuran beban dan memori pada perangkat target;
- pemantauan operasional yang berkelanjutan.